

技术报告 —— 从批次泄漏到可解释的肿瘤/正常分类器

项目：GeneTransformer · 日期：2026-09-13 · 状态：已完成

English version / 英文版: [technical_report.md](#)

摘要

我们最初的目标是用可解释的 Transformer 从 bulk 基因表达数据中预测**癌症类型**。严格的 留一数据集 (LODO) 评估揭示了一个关键事实：之前"100% 准确率"其实是**批次泄漏**——每个公开 GEO 系列本身就是单一癌症类型，因此"平台"与"类别"完全混杂，随机划分让任何模型都能靠记住平台拿到满分。在 LODO 下，多分类任务崩到随机水平 (macro-F1 = 0.0)，因为"未见过的癌症类型"与"未见过的批次"无法区分。转向跨平台可泛化的**肿瘤 vs 正常**二分类任务后（这里的信号真实存在且可迁移），Transformer 达到 **PR-AUC 0.9963 ± 0.0029 / ROC-AUC 0.9637 ± 0.0192**，与强基线 RBF-SVM 持平。SHAP 与 [CLS] 注意力归因揭示出一组跨折共识基因，以**肿瘤基质 / 细胞外基质 重塑**为主（胶原蛋白、DCN、DPT、FBLN2），并带有代谢分量（PFKFB3、LPL、PDK4）。通路富集 (Enrichr) 证实这是**唯一**通过多重检验校正的信号（GO:CC "含胶原的细胞外基质"，校正 $p = 3.9 \times 10^{-6}$ ）。本报告完整记录了混杂现象、任务转向、击败固定阈值的域偏移机制，以及随机森林增殖签名与 Transformer 基质签名之间的分歧。

1. 引言与任务

原始任务。用 Transformer 编码器从 bulk 微阵列表达数据中分类癌症类型（乳腺癌 BRCA、肺癌 LUAD、结直肠癌 COAD），并解释每一个预测。

泛化难题。这三类癌症可用的公开数据来自三个不同的 GEO 平台。由于每个平台恰好也是单一癌症类型，类别标签与批次相互混叠。项目的核心方法论问题因此变成：*模型学到的是生物学信号，还是批次？*我们用留一数据集协议 (§3) 来回答这个问题；在该协议暴露混杂之后，我们把任务重新聚焦到真正可迁移的信号上：肿瘤 vs 正常 (§4)。

2. 数据

取交集到共同的 14,725 个基因后，共 972 个 bulk **肿瘤/正常**样本，来自三个独立的 Affymetrix 平台：

平台 (GSE)	组织	样本数	正常	肿瘤
GSE31210	肺 (LUAD)	246	20	226
GSE39582	结直肠 (COAD)	585	19	566
GSE45827	乳腺 (BRCA)	141	11	130
合计		972	50	922


类别不平衡约为 18:1（肿瘤:正常），因此我们以阈值无关指标为主（\$5），并在支持类别权重的模型 中对正常类上采样权重。

预处理。 $\log_2(x + 1)$ → 逐基因 z-score → **按折高变基因 (HVG) 选择**（Transformer 取 训练集方差最大的 5000 个基因）。基线模型在相同的 HVG 特征上拟合，以保证公平对比。

3. 关键发现：批次泄漏

多分类任务存在致命的混杂。我们用三条相互独立的证据验证了这一点：

- 批次身份可被平凡预测。** 一个预测样本来自 *哪个 GSE 平台* 的分类器，在批次校正前得分 **1.0**，仅批次 ComBat 校正后为 0.980。癌症身份同样可被预测到 1.0——因为 *批次 == 类别*。
- 随机划分对照组发生泄漏。** 用随机训练/测试划分（也就是当初产生"100% 准确率"的设置），RF 与 SVM 都达到 **macro-F1 = 1.0**。
- LODO 崩到随机。** 每次留出一整个平台（一个未见过的癌症类型），两个基线都掉到 **macro-F1 = 0.0**——模型只能把留出样本判给 *见过的* 癌症类型，因此永远判错。



批次与癌症类别混叠 —— 批次校正前的 PCA

结论。 之前的 100% 准确率是批次效应，不是生物学信号。类别 == 批次，所以带癌症协变量的 ComBat 是奇异（共线）设计，而仅批次的 ComBat 会连同类别信号一起把批次抹掉。只有 LODO 能暴露这个混杂，而它表明：**仅凭这三个系列，跨平台的多分类癌症类型识别不可行。**这是决定性的负结果，它塑造了项目后续的全部走向。

4. 转向：二分类肿瘤/正常

肿瘤 vs 正常是另一种信号：它在每一个平台都存在，且不依赖于样本属于哪种具体癌症（因而也不依赖于批次）。因此我们把任务重新定义为 **LODO 下的二分类肿瘤/正常分类**——这是诚实且困难的泛化基准。后续所有结果均基于此任务。

5. 方法

模型

- **随机森林 (RF)** 与 **RBF-SVM** —— 在 HVG 特征上的强经典基线。
- **GeneTransformer** —— 每个基因有一个可学习的 $d=128$ 嵌入，乘以其表达值缩放；前置一个可学习的 [CLS] token；两层多头自注意力编码器 ($n_heads=4$ 、 $d_ff=256$ 、GELU、post-LN) 聚合上下文；[CLS] 输出送入 MLP 分类头 ($\rightarrow 64 \rightarrow 2$)。

评估


- **主指标为阈值无关的 PR-AUC 与 ROC-AUC。** 本任务弃用准确率 / F1 / 平衡准确率：在 $\approx 18:1$ 的不平衡与域偏移下，它们会退化成误导性的"全判肿瘤" 0.5，即使排序信号是真实的。
- **硬标签 (次要指标) 用分位数对齐：**每个留出折的分数在训练折的正常占比分位数处切分——在测试集上无标签依赖，也是唯一能扛过跨平台分数偏移的阈值 (§6)。
- **LODO** 每次留出一整个平台；每个测试折在训练中从未出现。

6. 结果 —— 二分类

模型 (LODO)	PR-AUC (均值 $\pm$ 标准差)	ROC-AUC (均值 $\pm$ 标准差)
随机森林	0.9961 $\pm$ 0.0025	0.9486 $\pm$ 0.0250
SVM (RBF)	0.9986 $\pm$ 0.0012	0.9776 $\pm$ 0.0154
Gene Transformer	0.9963 $\pm$ 0.0029	0.9637 $\pm$ 0.0192

Transformer 在 PR-AUC 上与 SVM 持平，在 ROC-AUC 上超过 RF，同时保持端到端可微——这正是 §7 的 归因分析所依赖的性质。

Tumor vs normal — LODO per-fold ROC & PR




ROC / PR 曲线 (LODO)

域偏移击败固定阈值

肿瘤/正常的排序可以跨平台迁移，但分数尺度不能。在训练折上模型饱和（肿瘤 ≈ 1.0 、正常 ≈ 0.0 ）；在留出折上，正常分数向上漂进肿瘤区间（测试正常中位数 ≈ 0.85 ），于是任何在训练折上学到的阈值都会把大多数留出正常样本误判。

Score-shift diagnosis: train-fit threshold does not transfer cross-platform



分数偏移：测试正常分数跨平台向肿瘤漂移

分位数对齐解决了这个问题：正常召回率从固定阈值下的 ≈ 0 升到 0.54 (RF) / 0.59 (SVM)。关键的是，`class_weight`（即便是 18:1） $\approx$ balanced 不能解决它——这个偏移是跨平台技术差异造成的分数尺度偏移，而不是类别先验问题。

7. 可解释性 —— SHAP 与 Attention

两种互补、纯推理的视角，回答模型为什么如此决策（无需重训；在 CPU 上从本地 checkpoint 运行）：


- **SHAP (Deep SHAP / Gradient × Input)**。对该架构，`shap.DeepExplainer` 退化为 $\text{SHAP}[s,i] = (x[s,i] - \text{mean}(\text{bg})[i]) \cdot \text{mean}(d \logit / d x_i)$ ，背景 = 分层训练均值，目标 = $\logit[\text{tumor}] - \logit[\text{normal}]$ 。以 `batch=1` 分块计算，因为 5001 个 token 的完整自注意力是 $O(n^2)$ ，在 ~5 GB 内存下会 OOM。
- **Attention ([CLS] → 基因)**。从每一层的 Q/K 投影权重重算 [CLS] token 的自注意力行 (`_cls_attention`)，只物化 CLS 行 ($O(L)$) ——与 `need_weights=True` 精确一致到 $1e-9$ ——再对层、头、测试样本取平均。

跨折聚合采用基于排名的、带缺席惩罚的方式：每个基因的逐折重要性转成排名（1 = 最重要）；某折 HVG 缺失的基因得最差排名（ $n_{\text{genes}}+1$ ）；两种方法的平均排名相加。这奖励那些跨平台稳定重要的基因，并对重尾的原始 SHAP/注意力分数稳健。


共识基因（前 20，基于排名，`n_folds=3`）

ZNF521, PFKFB3, COL4A5, LPL, AFAP1-AS1, CDO1, DPT, LCN2, COL11A1, ABCA8, ACADSB, CLTC, C2CD4A, EBF1, FLJ13744, LEPR, AR, EGR3, CA4, DCN


它们聚成两类生物学分组：**细胞外基质 / 基质重塑**（COL11A1、COL4A5、COL10A1、DCN、DPT、FBLN2、EFEMP1、CCDC80、ABI3BP、OGN、CLEC3B、EDIL3）与**代谢 / 信号**（PFKFB3 糖酵解、CDO1 甲基化标志、LCN2、LPL、PDK4、ACADSB、GPAM）。逐折 top 基因明显平台特异（GSE31210 → PLEKHH1/NEDD4；GSE39582 → GALNT7/SLC44A5；GSE45827 → CST1/GPR110/SCARA5），与域偏移相呼应 ——共识基因是三个平台都留存下来的部分。



SHAP 总结 —— GSE31210 (最清晰图 #1)




CLS 注意力 —— GSE31210 (最清晰图 #2)



SHAP 总结 —— GSE39582（最清晰图 #3：主导基因不同）

8. 通路富集（GO / KEGG / Reactome）

前 100 共识基因 → Enrichr（KEGG_2021_Human、GO_BP/MF/CC_2023、Reactome_2022）。



富集气泡图

唯一 FDR 显著的信号是细胞外基质 / 胶原组织：

库	通路	校正 p	重叠
GO:CC	Collagen-Containing Extracellular Matrix	3.9×10^{-6}	13
GO:CC	Extracellular Vesicle / Membrane-Bounded Organelle	0.0069	4
Reactome	Assembly of Collagen Fibrils & Other Multimeric Structures	0.043	4
Reactome	Extracellular Matrix Organization	0.043	7
Reactome	Collagen Formation / Chain Trimerization	0.043–0.049	3–4

KEGG、GO Biological Process 与 GO Molecular Function 均没有通过多重检验校正的项——它们最强的 名义显著命中（GO:BP "ECM Organization" 原始 $p = 2.6 \times 10^{-4}$ 、校正 $p = 0.088$ ；KEGG "AMPK signaling" 原始 $p = 0.022$ 、校正 $p = 0.48$ ；KEGG "Pathways in cancer" 校正 $p = 0.48$ ）只是趋势。我们如实 报告：共识基因集是一个**肿瘤基质 / ECM 重塑签名**，带有次级代谢分量——而不是经典的癌基因/抑癌 通路。

9. 讨论

1. **Transformer 看到的是肿瘤微环境。** 它最一致的基因是基质/ECM——胶原蛋白、decorin、dermatopontin、fibulin——这是肿瘤促结缔组织增生（desmoplasia）的标

志，而不是增殖程序。

2. **与 RF 增殖签名重叠低。** RF 的 top 基因是增殖标志 (*TPX2*、*ECT2*、*UBE2C*、*UBE2T*、*PPAT*、*BOP1*)；它们在 Transformer 中只排到约 1000–3000 (SHAP) / 400–900 (注意力)，且多个基因在若干折中缺失 (`n_folds < 3`)。这是可预期的：**(a)** HVG 按方差选基因，低方差的增殖基因经常被挤出 5000 基因的 Transformer 输入，而 RF 看到全部 ~15k 基因；**(b)** 两个模型的归纳偏置不同。Transformer 的 HVG 输入使它偏向高方差的基质信号。
3. **支配硬标签的是域偏移，而不是类别先验。** 在 LODO 下分数尺度跨平台漂移；只有分位数对齐能给出可用的硬标签。这是数据/特征选择的属性，不是架构的属性。
4. **决定性的结果是那个负结果。** 仅凭这些系列，跨平台多分类癌症类型识别不可行 (`批次 == 类别`)；肿瘤/正常信号才可行。任何后续工作都应先取得批次 $\neq$ 类别的数据 (例如 TCGA——单一平台、多癌种 + 配对正常) 再回到多分类。

局限性

- 可解释性在每个折上只跑 30 个分层测试样本 (受内存限制)，因此逐折排名是指示性的，并非穷尽。
- 富集前景是前 100 共识基因 (按排名)，不是差异表达统计检验；背景是 Enrichr 默认 (全体人类基因)。共识中的 lncRNA/loci (*AFAP1-AS1*、*FLJ13744*、*LOC285628*、...) 无法映射到通路，被 Enrichr 静默排除。
- Transformer 的 AUC 略逊于 SVM；我们未激进调参，因为项目目标是可解释性，而非在 AUC 上胜过 SVM。

可复现性

所有超参数与路径都在 `config.yaml` 中；随机种子固定为 42。命令：

```
python -m src.baseline、 python -m src.train、 python -m src.explain_tn、  
python -m src.enrichment。checkpoint、预处理矩阵与原始数据均 gitignore (可复现、不提交)。
```